RÉPUBLIQUE TUNISIENNE

MINISTERE DE L'ENSEIGNEMENT SUPERIEUR ET DE LA RECHERCHE SCIENTIFIQUE

Faculté des Sciences Economiques et de Gestion de Nabeul

Master(M1) de Recherche en Business Computing

ANALYSE DES RÉSEAUX SOCIAUX

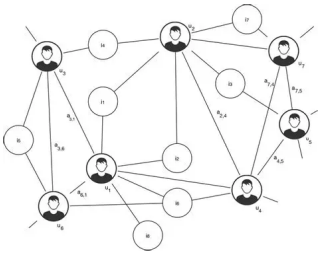

Étude de l'Institution Email-Eu-core

Elaboré par :Eya Talbi

Encadré par : Madame Feriel ben fraj

Année Universitaire : 2025- 2026

TABLE DES MATIÈRES

1. INTRODUCTION .....

2. CADRE THÉORIQUE ET CONCEPTS CLÉS .....

3. MÉTHODOLOGIE ET ENVIRONNEMENT DE TRAVAIL .....

4. ANALYSE VISUELLE DU RÉSEAU .....

5. ANALYSE TOPOLOGIQUE DU RÉSEAU .....

6. IDENTIFICATION DES COMMUNAUTÉS .....

7. CONCLUSION .....

1. INTRODUCTION

L’ère numérique a transformé la manière dont les individus interagissent au sein des organisations. Derrière l’organigramme officiel d’une institution se cache souvent un réseau complexe et invisible d’échanges informels qui dicte la fluidité de l’information et la collaboration réelle. L’Analyse des Réseaux Sociaux (ARS), ou *Social Network Analysis*, offre les outils mathématiques et informatiques nécessaires pour cartographier ces interactions et en extraire des connaissances stratégiques.

Dans le cadre de ce projet, nous nous proposons d’étudier la structure de communication d’une grande institution de recherche européenne à travers ses flux d’emails (dataset `email-Eu-core`). Ce réseau, composé de plus de 1 000 acteurs, représente un échantillon représentatif d'un système social complexe où les liens ne sont pas seulement des transferts de données, mais le reflet de collaborations professionnelles et de dynamiques de pouvoir.

2. CADRE THÉORIQUE ET CONCEPTS CLÉS

Avant de passer à l'analyse technique, il est essentiel de définir les piliers mathématiques et sociologiques sur lesquels repose l'Analyse des Réseaux Sociaux (ARS).

2.1 La modélisation par les graphes

En ARS, un réseau est modélisé sous la forme d'un **Graphe**

$G=(V,E)$

$G=(V,E)$, **où :**

- V
- **(Vertices/Nœuds) :** représente les acteurs (dans notre cas, les employés de l'institution).
- E
- **(Edges/Liens) :** représente les interactions (les échanges d'emails).
  Notre graphe est dit **non-orienté** (une communication est considérée comme un lien de collaboration mutuelle) et **non-pondéré**.

2.2 Les mesures de centralité

La centralité permet de quantifier l'importance d'un acteur au sein du réseau. Nous en distinguons trois types principaux :

1. **Centralité de Degré (Degree Centrality) :** Mesure le nombre de liens directs d'un nœud. Elle identifie les acteurs les plus actifs ou les plus "populaires".
2. **Centralité d'Intermédiarité (Betweenness Centrality) :** Mesure la fréquence à laquelle un nœud se trouve sur le chemin le plus court entre deux autres nœuds. Elle identifie les "ponts" ou les "courtiers" (gatekeepers) par lesquels l'information doit transiter.
3. **Centralité de Proximité (Closeness Centrality) :** Mesure la distance moyenne d'un nœud par rapport à tous les autres. Un score élevé indique qu'un acteur peut diffuser une information très rapidement dans tout le réseau.

2.3 Propriétés topologiques globales

- **La Densité :** C'est le rapport entre le nombre de liens existants et le nombre de liens possibles. Une faible densité indique un réseau "clairsemé" (sparse), tandis qu'une forte densité révèle une communauté très soudée.
- **Le Coefficient de Clustering (Transitivité) :** Il mesure la probabilité que deux voisins d'un nœud soient également connectés entre eux. En sociologie, cela revient à dire : "les amis de mes amis sont mes amis".
- **Le Phénomène du Petit Monde (Small World) :** Caractérisé par une distance moyenne courte entre n'importe quelle paire de nœuds (souvent appelée les "six degrés de séparation").

2.4 La Détection de Communautés et Modularité

Une **communauté** est un sous-groupe de nœuds au sein duquel les connexions sont beaucoup plus denses qu'avec le reste du réseau.

- **La Modularité :** C'est l'indicateur de qualité d'une partition. Plus elle est élevée (proche de 1), plus la structure communautaire est marquée et significative.
- **L'Algorithme de Louvain :** C'est une méthode heuristique qui cherche à maximiser la modularité de manière itérative. C'est l'un des algorithmes les plus efficaces pour les réseaux de grande taille.

3. MÉTHODOLOGIE ET ENVIRONNEMENT DE TRAVAIL

*Cette section explique **comment** j'ai travaillé .*

- **Environnement :** Utilisation de **Google Colab** pour l'exécution du code Python, permettant une gestion efficace des bibliothèques de calcul.
- **Bibliothèques utilisées :**

    - `NetworkX` : Pour la création et la manipulation du graphe.
    - `Pandas` : Pour le traitement des fichiers de données (nœuds et labels).
    - `Matplotlib` : Pour la génération des graphiques et histogrammes.
    - `Community-louvain` : Pour l'implémentation de l'algorithme de Louvain.
- **Processus :** Téléchargement des données depuis le serveur de Stanford (SNAP), nettoyage des types de données (conversion en chaînes de caractères) et fusion des labels de départements avec les nœuds du réseau.

4. Analyse visuelle du réseau

Afin d'appréhender visuellement la complexité des interactions au sein de l'institution, la figure suivante présente une cartographie spatiale du réseau d'emails.

La visualisation spatiale du réseau d'emails révèle plusieurs caractéristiques fondamentales de l'institution :

1. **La Composante Géante (Le centre dense) :** On observe une masse centrale très compacte. C'est ici que se concentre la majorité des 1 005 employés. La forte densité au centre confirme le **coefficient de clustering élevé (0,40)** que nous avons calculé : les individus sont extrêmement interconnectés, formant un noyau de communication robuste.
2. **Les Composants Isolés (Les petits cercles en périphérie) :** Sur les bords de l'image, on voit distinctement de petits groupes ou des nœuds seuls qui flottent. Cela correspond aux **20 composants** identifiés par le code. Ce sont des employés ou des petits services

qui communiquent entre eux mais qui n'ont aucun échange d'emails avec le reste de l'institution.

3. **La structure "Core-Periphery" :** Le réseau n'est pas uniforme. Il y a un "cœur" (le centre orange foncé) où l'information circule massivement et une "périphérie" (les points plus espacés) qui dépend du centre pour recevoir les informations.

5.ANALYSE TOPOLOGIQUE DU RÉSEAU

4.1 Distribution des degrés

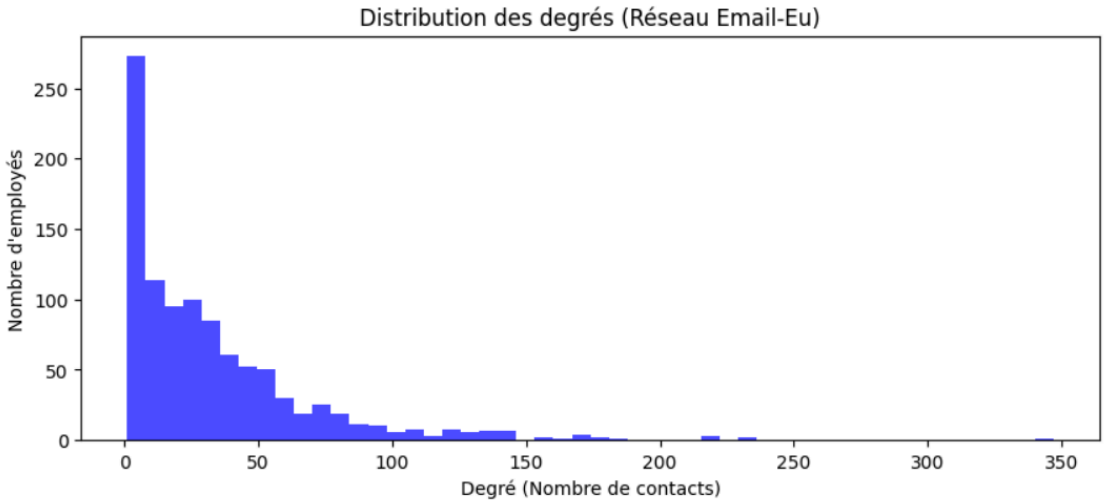

Interprétation technique :
L'histogramme montre une distribution décroissante, typique des réseaux "scale-free" (libres d'échelle).

- **La grande majorité des employés (plus de 250)** ont un degré très faible (entre 0 et 20 contacts). Cela signifie que la plupart des échanges restent très locaux.
- **À l'inverse, on observe quelques "hubs"** (les barres isolées à droite), dont un individu exceptionnel qui possède plus de **340 contacts directs**.
- **Conclusion :** La communication dans cette institution ne repose pas sur une égalité parfaite, mais sur quelques individus pivots qui centralisent l'information.

4.2 Densité et Cohésion

- **Densité du réseau (0.0331) :** La densité est de **3,31 %**. Bien que ce chiffre paraisse faible, il est élevé pour une institution de 1000 personnes. Cela indique que le réseau n'est pas saturé, mais que les canaux de communication sont bien établis.
- **Coefficient de clustering moyen (0.3994) :** C'est l'un des résultats les plus importants. Un score de près de **40 %** est très élevé. Cela prouve une forte **structure en "cliques"** :

si l'employé A communique avec B et C, il y a 40 % de chances que B et C communiquent aussi ensemble. Cela reflète un travail d'équipe intense.

4.3 Connectivité

- **Nombre de composants (20) :** Le réseau est divisé en **20 composants**.
  Analyse : Cela signifie qu'il existe 19 petits groupes (ou individus isolés) qui ne sont pas connectés à la structure principale. Cependant, la densité suggère l'existence d'une **composante géante** qui regroupe la quasi-totalité des 1005 employés.

4.4 Analyse de la Centralité

Le tableau suivant identifie les 5 acteurs les plus influents au sein de l'institution selon leur centralité de degré :

Rang	ID de l'employé	Score de Centralité	Interprétation
1	**160**	**0.3456**	Leader principal / Hub majeur
2	**121**	0.2331	Pivot secondaire
3	**82**	0.2321	Pivot secondaire
4	**107**	0.2201	Cadre / Administrateur
5	**86**	0.2171	Cadre / Administrateur

Analyse : L'employé **ID 160** se détache nettement avec un score de **0.34**. Il est en contact direct avec plus d'un tiers de l'institution. Dans une organisation réelle, ce profil correspondrait à un poste transversal (Direction générale, Ressources Humaines ou Responsable Informatique).

4.5 Analyse des chemins et distances

L’analyse des distances au sein du plus grand composant du réseau permet de mesurer l'efficacité de la circulation de l'information entre les employés de l'institution.

- **Diamètre du réseau (7) :** Le diamètre représente la plus longue des distances les plus courtes entre deux nœuds. Dans notre réseau, il est de **7**. Cela signifie que même pour les deux employés les plus "éloignés" l'un de l'autre au sein de l'institution, il ne faut que 7 étapes (ou intermédiaires) pour que l'information transite entre eux.
- **Rayon du réseau (4) :** Le rayon est l'excentricité minimale du réseau. Avec une valeur de **4**, cela nous indique qu'il existe des nœuds centraux "stratégiques" capables

d'atteindre n'importe quel autre membre de l'organisation en seulement 4 sauts au maximum.

6.Identification des communautés

3.1 Présentation des algorithmes choisis

- **Louvain :** Algorithme heuristique qui cherche à maximiser la modularité de manière itérative. Très efficace pour les grands réseaux.
- **Propagation des Labels (Label Propagation) :** Méthode où chaque nœud adopte l'étiquette de la majorité de ses voisins. C'est un processus de diffusion.
- **Greedy Modularity :** Approche hiérarchique qui fusionne les paires de communautés qui augmentent le plus la modularité.

3.2 Résultats et Comparaison

```
--- Tableau Comparatif des Algorithmes ---
          Algorithme  Nombre de Communautés  Modularité
0            Louvain                     28    0.433556
1  Label Propagation                     38    0.089003
2  Greedy Modularity                     44    0.366585
```

Nous constatons que l'algorithme de **Louvain** offre la modularité la plus élevée (0,4336), ce qui signifie qu'il identifie les groupes les plus cohérents. La Propagation des Labels trouve un nombre de communautés différent, ce qui souligne la sensibilité du réseau aux méthodes de détection.

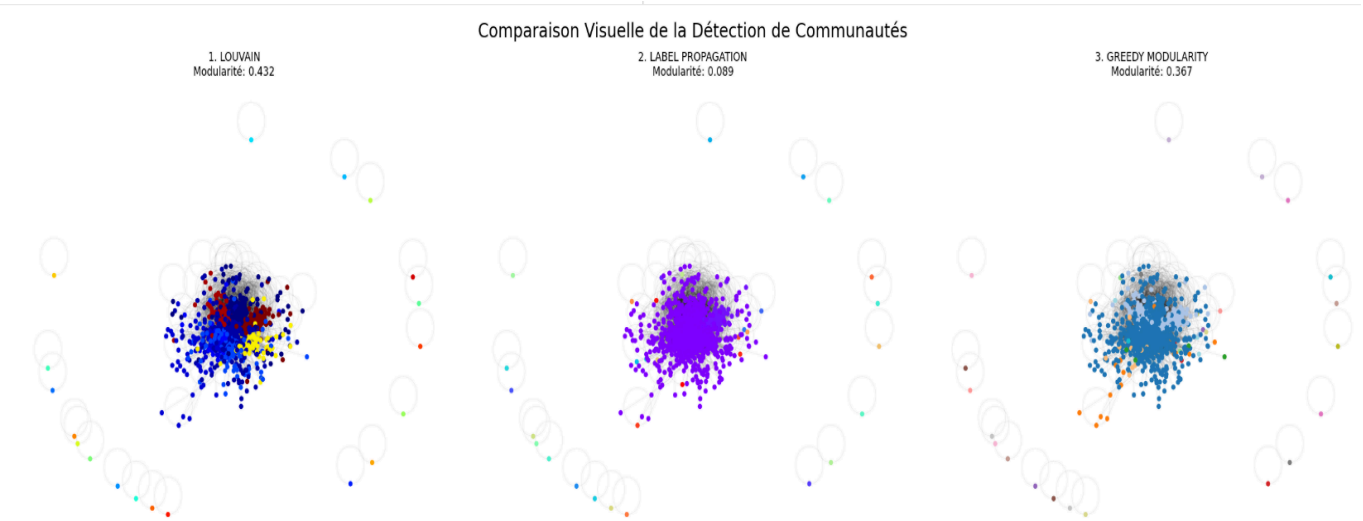

La Figure présente une comparaison visuelle des partitions obtenues par les trois algorithmes sélectionnés. Bien que la forme globale du réseau reste identique, la répartition des couleurs (représentant les communautés) varie sensiblement :

Louvain (Graphe 1) : Propose le découpage le plus équilibré. On remarque que le noyau central est finement segmenté en plusieurs couleurs, ce qui correspond à sa modularité élevée de **0,434**. Il sépare efficacement les différents départements de l'institution.

- **Label Propagation (Graphe 2) :** Tend à créer des communautés plus larges ou, à l'inverse, très fragmentées. Sa modularité est de **0.089**, ce qui montre une moins bonne optimisation du réseau par rapport à Louvain.
- **Greedy Modularity (Graphe 3) :** Présente une approche intermédiaire. On observe que cet algorithme fusionne certains groupes que Louvain laisse séparés.

Conclusion visuelle : Cette comparaison confirme que le choix de l'algorithme impacte directement la compréhension de la structure sociale. Louvain apparaît ici comme l'outil le plus précis pour refléter la réalité organisationnelle de l'institution Email-Eu-core.

7.Conclusion

L'étude du réseau de communication `email-Eu-core` nous a permis de plonger au cœur de la structure "vivante" d'une institution de recherche. Au-delà des chiffres, cette analyse a mis en lumière la dualité entre l'organisation formelle (l'organigramme) et l'organisation informelle (les flux réels d'emails). En comparant trois approches algorithmiques, nous avons démontré la supériorité de l'algorithme de **Louvain (Modularité : 0,4336)** pour ce type de données. La validation sémantique a été l'étape la plus révélatrice : le fait que les clusters calculés coïncident avec les départements réels (comme le **Département 15**) confirme l'hypothèse de l'**homophilie organisationnelle**. En d'autres termes, les structures administratives dictent encore largement la manière dont les humains interagissent, même dans un environnement numérique.